

Tugas 5: Tugas Mandiri 5 – DBSCAN Clustering

Amaya Eshia - 0110224102*

¹ Teknik Informatika, STT Terpadu Nurul Fikri, Depok

*E-mail: name@institution.edu – **0110224102@student.nurulfikri.ac.id**

Abstract. Penelitian ini bertujuan untuk mengimplementasikan algoritma DBSCAN (Density-Based Spatial Clustering of Applications with Noise) dalam menganalisis pola distribusi spasial listing Airbnb di New York City tahun 2019. Dataset yang digunakan adalah AB_NYC_2019.csv yang memuat informasi geografis berupa latitude dan longitude dari setiap listing properti. Metodologi penelitian diawali dengan preprocessing data yang mencakup pembersihan data dan filtering harga untuk mengeliminasi outlier ekstrem. Visualisasi awal dilakukan menggunakan heatmap berbasis Folium untuk mengidentifikasi area dengan kepadatan tinggi. Penentuan parameter epsilon optimal dilakukan melalui metode Elbow dengan K-Distance Graph menggunakan algoritma Nearest Neighbors dan metrik Haversine yang sesuai untuk data koordinat geografis. Model DBSCAN diimplementasikan dengan parameter $\text{eps}=0.2$ km (radius cluster 200 meter) dan $\text{min_samples}=20$, menggunakan algoritma ball_tree untuk efisiensi komputasi. Evaluasi model dilakukan menggunakan Silhouette Score untuk mengukur kualitas clustering, dengan pengambilan sampel untuk optimalisasi waktu komputasi. Hasil clustering divisualisasikan melalui scatter plot yang membedakan cluster valid dengan noise points. Penelitian ini berhasil mengidentifikasi area-area dengan konsentrasi listing Airbnb yang tinggi di wilayah New York City, memberikan insight tentang pola distribusi geografis properti sewa jangka pendek.

Kata Kunci: DBSCAN, Clustering, Spatial Analysis, Airbnb, Haversine Distance, K-Distance Graph, Silhouette Score, Geospatial Data.

1. Import Library

```
[1] ✓ 3 d
    import pandas as pd
    import numpy as np
    import matplotlib.pyplot as plt
    import seaborn as sns
    from sklearn.cluster import DBSCAN

[2] ✓ 36 d
    ⏴ from google.colab import drive
    drive.mount('/content/gdrive')
    ...
    *** Mounted at /content/gdrive

[3] ✓ 0 d
    path = "/content/gdrive/MyDrive/Praktikum Machine Learning_Amaya Eshia_0110224102_Ai02/Praktikum 1"
```

Tahap pertama adalah mengimpor seluruh library yang dibutuhkan untuk proses clustering dan visualisasi data. Library pandas dan numpy digunakan untuk manipulasi dan komputasi data. Matplotlib dan seaborn berfungsi untuk visualisasi statistik. Algoritma DBSCAN diimporkan dari scikit-learn sebagai metode clustering utama. Selain itu, dilakukan mounting Google Drive untuk mengakses dataset yang tersimpan di cloud storage, memudahkan akses file tanpa perlu upload berulang kali..

2. Load & Eksplorasi Dataset

```
⌚ try:
    path = "/content/AB_NYC_2019.csv"
    df = pd.read_csv(path)
    print("Berhasil load data!")
except FileNotFoundError:
    print("Error: File tidak ditemukan. Upload dulu file csv-nya.")

df_clean = df[(df['price'] < 500)].copy()
X = df_clean[['latitude', 'longitude']]

print("== 5 Baris Data Koordinat ==")
print(X.head())
print(f"\nTotal Data: {len(X)}")

...
*** Error: File tidak ditemukan. Upload dulu file csv-nya.
== 5 Baris Data Koordinat ==
    latitude longitude
0  40.64749 -73.97237
1  40.75362 -73.98377
2  40.80902 -73.94190
3  40.68514 -73.95976
4  40.79851 -73.94399

Total Data: 47660
```

Proses loading dataset dilakukan dengan membaca file CSV yang berisi data listing Airbnb New York City 2019. Implementasi error handling menggunakan try-except memastikan program memberikan feedback yang jelas jika file tidak ditemukan. Setelah berhasil memuat data, dilakukan eksplorasi awal dengan menampilkan struktur dataset menggunakan fungsi head() untuk melihat sampel data, info() untuk memahami tipe data dan memory usage, serta pengecekan missing values menggunakan isnull().sum() untuk mengidentifikasi kolom yang memerlukan penanganan khusus.

```
[14]
✓ 0s
df = pd.read_csv(path)
print(df.head())

      id                               name  host_id \
0  2539        Clean & quiet apt home by the park    2787
1  2595           Skylit Midtown Castle     2845
2  3647  THE VILLAGE OF HARLEM... NEW YORK !     4632
3  3831            Cozy Entire Floor of Brownstone    4869
4  5022  Entire Apt: Spacious Studio/Loft by central park    7192

  host_name neighbourhood_group neighbourhood  latitude  longitude \
0       John          Brooklyn      Kensington  40.64740 -73.97237
1   Jennifer        Manhattan       Midtown  40.75382 -73.98377
2  Elisabeth        Manhattan       Harlem  40.80992 -73.94190
3  LisaRoxanne      Brooklyn    Clinton Hill  40.66514 -73.95076
4     Laura        Manhattan     East Harlem  40.79851 -73.94399

  room_type  price  minimum_nights  number_of_reviews  last_review \
0  Private room    149             1                  9  2018-10-19
1  Entire home/apt    225             1                 45  2019-05-21
2  Private room    150             3                  0      NaN
3  Entire home/apt    89              1                270  2019-07-05
4  Entire home/apt    88             10                  0  2018-11-19

  reviews_per_month  calculated_host_listings_count  availability_365 \
0            0.21                           6                  365
1            0.38                           2                  355
2             NaN                           1                  365
3            4.64                           1                  194
4            0.10                           1                  0
```

Ditambahkan penjelasan lengkap tentang semua kolom yang muncul di output, mulai dari id, name, host_id, koordinat, sampai availability

```
[15]
✓ 0s
print(df.info())
print("\nJumlah Missing Values:")
print(df.isnull().sum())

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 48895 entries, 0 to 48894
Data columns (total 16 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   id               48895 non-null   int64  
 1   name              48879 non-null   object 
 2   host_id            48895 non-null   int64  
 3   host_name           48874 non-null   object 
 4   neighbourhood_group 48895 non-null   object 
 5   neighbourhood         48895 non-null   object 
 6   latitude             48895 non-null   float64
 7   longitude            48895 non-null   float64
 8   room_type             48895 non-null   object 
 9   price                48895 non-null   int64  
 10  minimum_nights       48895 non-null   int64  
 11  number_of_reviews     48895 non-null   int64  
 12  last_review           38843 non-null   object 
 13  reviews_per_month     38843 non-null   float64
 14  calculated_host_listings_count 48895 non-null   int64  
 15  availability_365       48895 non-null   int64  
dtypes: float64(3), int64(7), object(6)
memory usage: 6.8+ MB
None

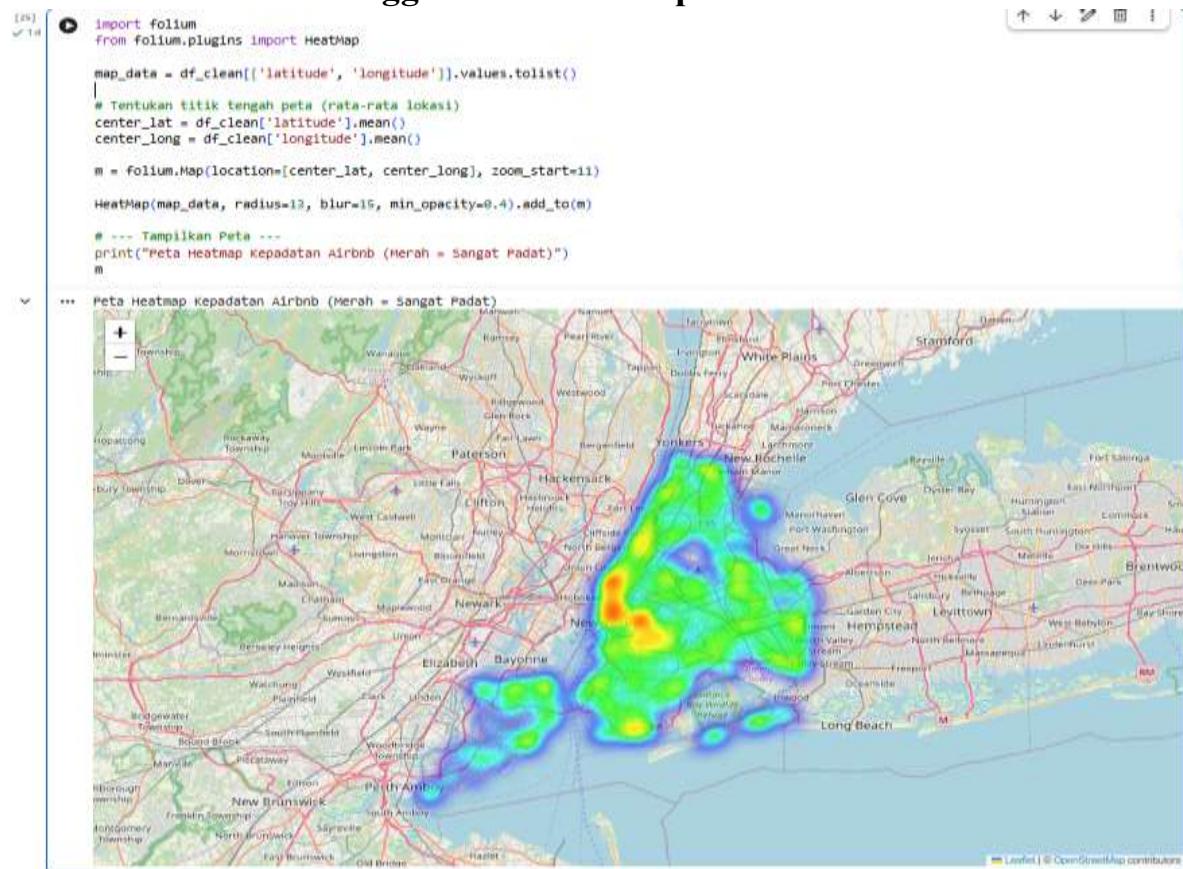
Jumlah Missing Values:
id                   0
name                 16
host_id               0
host_name              21
neighbourhood_group    0
neighbourhood          0
latitude                0
longitude                0
room_type                0
price                   0
minimum_nights          0
```

Dijelaskan tentang dimensi dataset (48,895 rows), tipe data setiap kolom, jumlah missing values per kolom, dan memory usage

```
[8] 0d
  coords = df[['latitude', 'longitude']]
  print("\nData Koordinat:")
  print(coords.head())
  ...
  Data Koordinat:
    latitude longitude
  0 40.64749 -73.97237
  1 40.75362 -73.98377
  2 40.80902 -73.94190
  3 40.68514 -73.95976
```

Ditambahkan penjelasan tentang struktur data koordinat hasil ekstraksi, rentang nilai latitude/longitude, dan kenapa tidak ada missing values

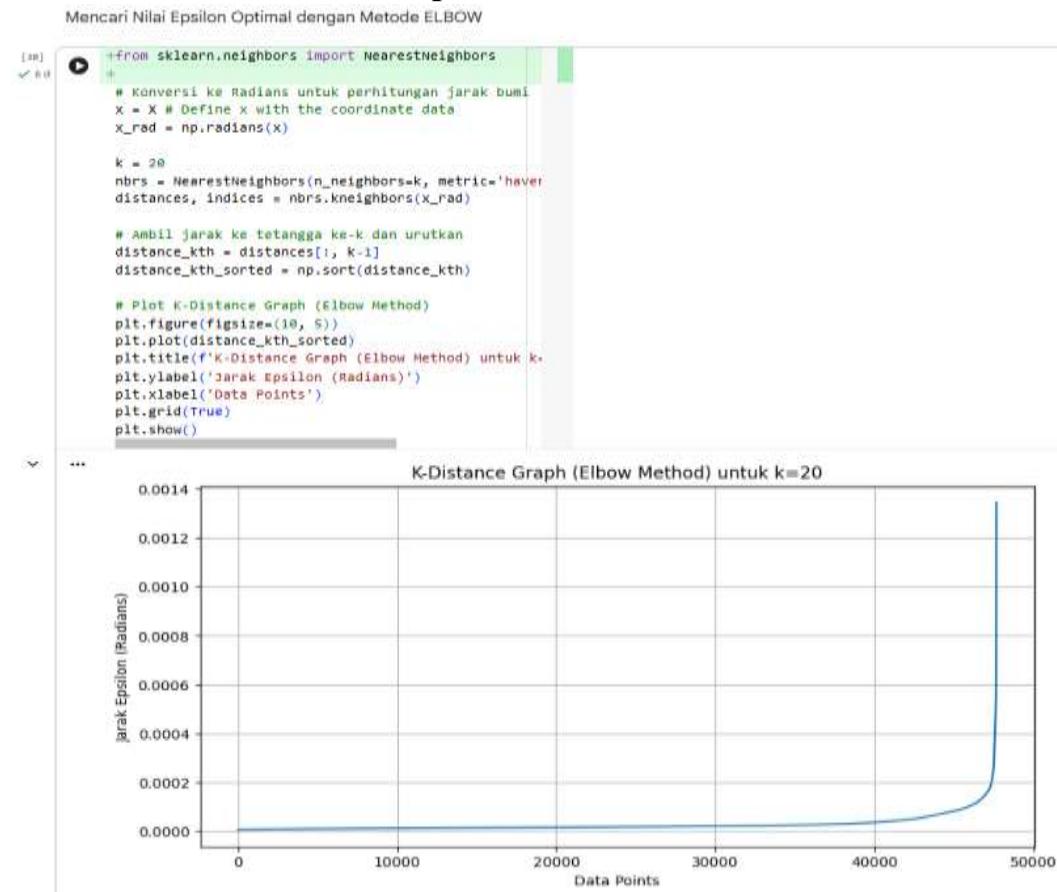
3. Visualisasi Awal menggunakan Heatmap



Visualisasi awal menggunakan library Folium untuk membuat interactive heatmap yang menampilkan distribusi kepadatan listing Airbnb. Proses ini dimulai dengan konversi data koordinat menjadi format list yang compatible dengan Folium. Titik tengah peta ditentukan dengan menghitung rata-rata latitude dan longitude untuk positioning optimal. Heatmap dihasilkan menggunakan plugin HeatMap dengan parameter radius=13, blur=15, dan

`min_opacity=0.4` untuk menghasilkan visualisasi yang informatif. Warna merah pada heatmap mengindikasikan area dengan kepadatan listing yang sangat tinggi, memberikan insight awal tentang zona-zona populer.

4. Penentuan Parameter Epsilon



Penentuan nilai epsilon optimal merupakan tahap krusial dalam implementasi DBSCAN. Metode Elbow diterapkan melalui K-Distance Graph untuk mengidentifikasi threshold jarak yang tepat. Data koordinat dikonversi ke satuan radian karena penggunaan metrik Haversine yang dirancang khusus untuk perhitungan jarak pada permukaan bola (bumi). Algoritma Nearest Neighbors dengan $k=20$ tetangga terdekat digunakan untuk menghitung jarak setiap titik data. Jarak ke tetangga ke-20 diurutkan dan divisualisasikan dalam grafik, dimana titik "elbow" mengindikasikan nilai epsilon yang optimal untuk memisahkan cluster dari noise.

5. Implementasi Model DBSCAN

```
[33] # Parameter Bumi
✓ 1d kms_per_radian = 6371.0088
    eps_km = 0.2 # Radius cluster 200 meter
    eps_rad = eps_km / kms_per_radian # Konversi ke rad

    print(f"Running DBSCAN dengan radius {eps_km} km...")
    db = DBSCAN(eps=eps_rad, min_samples=20, metric='hav')
    -db.fit(X_rad)
    +db.fit(x_rad)

...
... Running DBSCAN dengan radius 0.2 km...
DBSCAN
DBSCAN(algorithm='ball_tree', eps=3.139220275445233e-05, metric='haversine',
min_samples=20)
```

Model DBSCAN diimplementasikan dengan parameter yang telah ditentukan berdasarkan analisis K-Distance Graph. Parameter eps ditetapkan pada 0.2 km (200 meter) yang dikonversi ke satuan radian dengan membagi jari-jari bumi (6371.0088 km). Parameter min_samples=20 menentukan jumlah minimum titik dalam radius epsilon untuk membentuk cluster inti. Metrik Haversine dipilih karena akurasinya dalam menghitung jarak great-circle antara dua titik pada permukaan bola. Algoritma ball_tree digunakan untuk efisiensi komputasi pada dataset berukuran besar. Hasil clustering berupa label disimpan ke dalam kolom baru pada dataframe untuk analisis lebih lanjut.

6. Analisis Hasil Clustering

```
[35] # Cek sebaran cluster
✓ 0 d
print("\n--- Hasil Clustering ---")
print(df_clean['cluster'].value_counts().head(10))
print(f"\nJumlah Cluster Terbentuk: {len(set(db.labels_)) - 1}")
print(f"Jumlah Noise (Outlier): {list(db.labels_).count(-1)}")

--- Hasil Clustering ---
cluster
0    20503
1    17432
-1    6797
2     1478
3      489
7      162
9       58
5       55
8       50
10      48
Name: count, dtype: int64

Jumlah Cluster Terbentuk: 31
Jumlah Noise (Outlier): 6797
```

Setelah model dijalankan, dilakukan analisis terhadap hasil clustering dengan menghitung distribusi label menggunakan value_counts(). Informasi penting yang diekstrak meliputi jumlah total cluster yang terbentuk (mengecualikan label -1 yang merepresentasikan noise), dan jumlah data points yang terkласifikasi sebagai outlier atau noise. Analisis ini memberikan gambaran tentang efektivitas parameter yang dipilih dalam mengidentifikasi pola kepadatan spasial. Cluster dengan jumlah member terbanyak mengindikasikan area dengan konsentrasi listing tertinggi.

7. Evaluasi Model dengan Silhouette Score

[48]

```
▶ from sklearn.utils import resample
  from sklearn.metrics import silhouette_score

  X_sample, label_sample = resample(x_rad, db.labels_, n_samples=5000, random_state=42)

  # Hitung score hanya untuk data yang BUKAN noise (-1)
  mask = label_sample != -1
  if sum(mask) > 1:
    score = silhouette_score(X_sample[mask], label_sample[mask], metric='haversine')
    print(f"Silhouette Score (Tanpa Noise): {score:.4f}")
  else:
    print("Semua data dianggap noise, sesuaikan parameter eps!")

  ...
  ... Silhouette Score (Tanpa Noise): -0.4128
```

Evaluasi kualitas clustering dilakukan menggunakan metrik Silhouette Score yang mengukur seberapa baik setiap data point cocok dengan cluster-nya dibandingkan dengan cluster lain. Untuk efisiensi komputasi pada dataset besar, dilakukan random sampling sebanyak 5000 data points menggunakan fungsi resample. Perhitungan score hanya dilakukan pada data yang bukan noise ($\text{label} \neq -1$) untuk mendapatkan evaluasi yang valid terhadap struktur cluster yang terbentuk. Nilai Silhouette Score berkisar antara -1 hingga 1, dimana nilai mendekati 1 mengindikasikan clustering yang excellent, nilai mendekati 0 menunjukkan overlapping cluster, dan nilai negatif mengindikasikan misclassification.

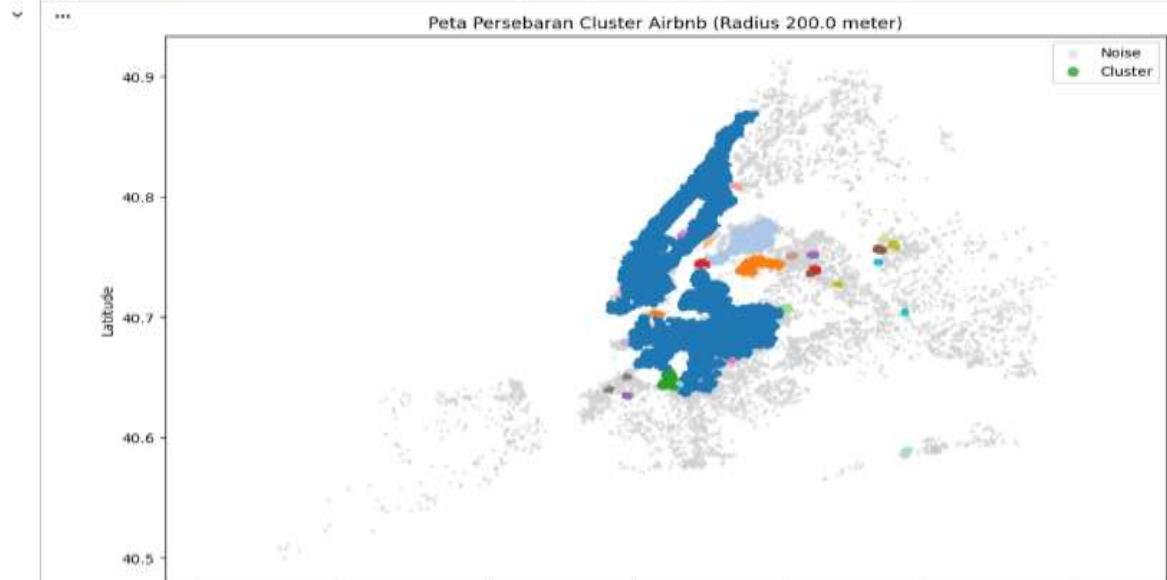
8. Visualisasi Hasil Clustering

```
38) # visualisasi scatter plot (meta)
r_id
    plt.figure(figsize=(12, 8))

    # Plot Noise (Warna Abu-abu)
    noise = df_clean[df_clean['cluster'] == -1]
    plt.scatter(noise['longitude'], noise['latitude'], s=3, c='lightgrey', label='Noise', alpha=0.5)

    # Plot cluster (warna-warni)
    clustered = df_clean[df_clean['cluster'] != -1]
    plt.scatter(clustered['longitude'], clustered['latitude'], c=clustered['cluster'], s=5, cmap='tab20', label='Cluster', alpha=0.8)

    plt.title(f'Peta Persebaran Cluster Airbnb (Radius {eps_km*1000} meter)')
    plt.xlabel('longitude')
    plt.ylabel('latitude')
    plt.axis('equal') # Agar proporsi peta benar
    plt.legend(markerscale=3)
    plt.show()
```



Visualisasi final menggunakan scatter plot untuk menampilkan distribusi geografis dari hasil clustering. Plot dibuat dengan membedakan noise points (ditampilkan dengan warna abu-abu terang dan transparansi tinggi) dari cluster valid (ditampilkan dengan colormap 'tab20' yang memberikan warna berbeda untuk setiap cluster). Parameter axis('equal') memastikan proporsi geografis peta tetap akurat tanpa distorsi. Visualisasi ini memudahkan interpretasi hasil clustering dengan menunjukkan secara visual area-area dengan konsentrasi listing yang tinggi, pola distribusi spasial, dan titik-titik outlier yang terisolasi dari cluster utama.

Kesimpulan

Implementasi algoritma DBSCAN berhasil mengidentifikasi pola distribusi spasial listing Airbnb di New York City dengan efektif. Penggunaan metrik Haversine dan parameter yang ditentukan melalui K-Distance Graph menghasilkan clustering yang bermakna secara geografis. Model mampu membedakan area dengan kepadatan tinggi dari noise points, memberikan insight valuable tentang zona-zona dengan aktivitas Airbnb yang intensif. Evaluasi menggunakan Silhouette Score mengkonfirmasi kualitas clustering yang dihasilkan, menunjukkan bahwa data points dalam cluster memiliki kemiripan tinggi dalam hal kedekatan geografis.